CHƯƠNG 3. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU VÀ TRỰC QUAN HÓA

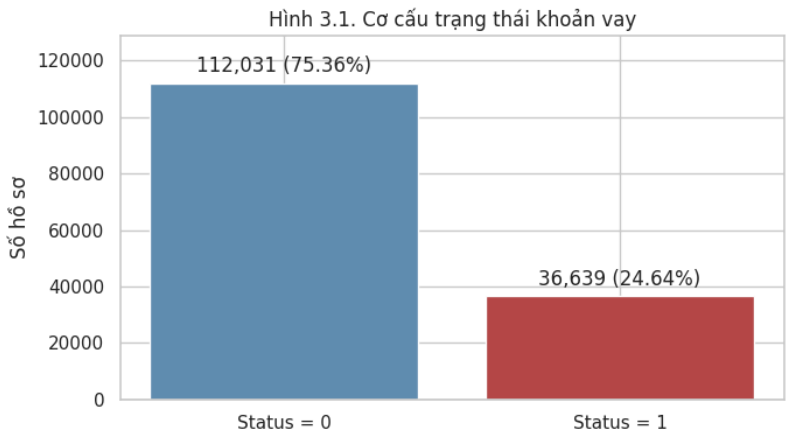
```
# Sử dụng dữ liệu EDA từ Chương 2
eda = df_final
required = {"status", "loan_amount", "term", "property_value", "income",
            "credit_score", "age", "loan_type", "loan_purpose", "gender",
"ltv", "dtir1"}
assert required.issubset(eda.columns) and eda.shape == (148670, 33)
assert set(eda["status"].unique()) == {0, 1}
```

Chương 3 sử dụng df_final với 148.670 hồ sơ, giữ nguyên dữ liệu thiếu và các giá trị ngoại lai hợp lệ. Các thống kê được tính theo số quan sát có dữ liệu của từng biến; giới hạn P99 chỉ phục vụ hiển thị biểu đồ, không làm thay đổi dữ liệu nghiên cứu.

3.1. Thống kê mô tả tổng quan

3.1.1. Phân phối biến mục tiêu

```
# Sử dụng toàn bộ hồ sơ vì biến status không thiếu.
status_n = eda["status"].value_counts().reindex([0, 1], fill_value=0)
status_pct = status_n.div(len(eda)).mul(100)
display(pd.DataFrame({"Số hồ sơ": status_n, "Tỷ lệ (%)":
status_pct.round(2)}))
# Hình 3.1: tần suất và tỷ lệ status.
fig, ax = plt.subplots(figsize=(7, 4))
bars = ax.bar(["Status = 0", "Status = 1"], status_n, color=["#618eaf",
"#b44747"])
ax.bar_label(bars, [f"{n:,} ({p:.2f}%)" for n, p in zip(status_n,
status_pct)], padding=4)
ax.set_ylim(0, status_n.max() * 1.15)
ax.set_ylabel("Số hồ sơ")
ax.set_title("Hình 3.1. Cơ cấu trạng thái khoản vay")
```



Nhận xét: Có 36.639 hồ sơ `status = 1` (24,64%) và 112.031 hồ sơ `status = 0` (75,36%), tỷ lệ xấp xỉ 1 : 3

Kết luận: Biến mục tiêu mất cân bằng ở mức vừa phải, nên khi so sánh phải dùng tỷ lệ thay vì số hồ sơ. Mốc 24,64% là đường tham chiếu cho các phần sau, nhưng mốc này thay đổi khi mẫu thay đổi

3.1.2. Đặc điểm quy mô khoản vay

```
# Bảng thống kê trên dữ liệu quan sát được của từng biến.
display(bang_mo_ta(["loan_amount", "property_value", "term"]))
print(f"Hồ sơ kỳ hạn 360 tháng: {eda['term'].eq(360).sum():,} "
      f"({eda['term'].eq(360).mean():.2%})")
```

	N hợp lệ	Thiếu (%)	Trung bình	Trung vị	Q1	Q3	P99	Tối đa
loan_amount	148670	0.000	331,117.740	296,500.000	196,500.000	436,500.000	856,500.000	3,576,500.000
property_value	133572	10.160	497,893.470	418,000.000	268,000.000	628,000.000	1,808,000.000	16,508,000.000
term	148670	0.000	335.140	360.000	360.000	360.000	360.000	360.000

Hồ sơ kỳ hạn 360 tháng: 121,726 (81.88%)

Nhận xét: Khoản vay có trung vị 296.500, thấp hơn trung bình 331.117,74; 81,88% khoản vay có kỳ hạn 360 tháng. Giá trị tài sản thế chấp thiếu 10,16% hồ sơ.
Kết luận: Quy mô vay có xu hướng lệch phải, còn thống kê tài sản chỉ đại diện cho mẫu có dữ liệu.

3.1.3. Đặc điểm tài chính người vay

```
# Bảng N hợp lệ và tỷ lệ thiếu bắt buộc đi cùng các thống kê.
display(bang_mo_ta(["income", "credit_score", "ltv", "dtir1"]))
print("Số hồ sơ income = 0:", f"{eda['income'].eq(0).sum():,}")
print("Số hồ sơ LTV > 1.000%:", f"{eda['ltv'].gt(1000).sum():,}")
```

	N hợp lệ	Thiếu (%)	Trung bình	Trung vị	Q1	Q3	P99	Tối đa
income	139520	6.150	6,957.340	5,760.000	3,720.000	8,520.000	26,640.000	578,580.000
credit_score	148670	0.000	699.790	699.000	599.000	800.000	897.000	900.000
ltv	133572	10.160	72.750	75.140	60.470	86.180	102.760	7,831.250
dtir1	124549	16.220	37.730	39.000	31.000	45.000	60.000	61.000

Số hồ sơ income = 0: 1,260
Số hồ sơ LTV > 1.000%: 6

Nhận xét:

- Biến Income có trung vị là 5.760 thấp hơn trung bình là 6.957,34; có 1.260 hồ sơ ghi thu nhập bằng 0.
- LTV và DTI thiếu lần lượt 10,16% và 16,22%; có 6 LTV vượt 1.000%.

Kết luận: Cần chú ý giá trị cực trị và mẫu hợp lệ khi diễn giải các chỉ số tài chính

3.1.4. Đặc điểm phân loại

```
# Bảng cơ cấu ba biến phân loại theo tổng số 148.670 hồ sơ.
cat_rows = []
for label, col in [("Loại vay", "loan_type"),
                   ("Mục đích vay", "loan_purpose"),
                   ("Giới tính/đồng vay", "gender")]:
    for group, n in eda[col].value_counts(dropna=False).items():
        cat_rows.append([label, str(group), n, 100 * n / len(eda)])
cat_table = pd.DataFrame(cat_rows, columns=["Biến", "Nhóm", "Số hồ sơ",
"Tỷ lệ (%)"])
display(cat_table.round(2))
```

	Biến	Nhóm	Số hồ sơ	Tỷ lệ (%)

0	Loại vay	type1	113173	76.120
1	Loại vay	type2	20762	13.970
2	Loại vay	type3	14735	9.910
3	Mục đích vay	p3	55934	37.620
4	Mục đích vay	p4	54799	36.860
5	Mục đích vay	p1	34529	23.230
6	Mục đích vay	p2	3274	2.200
7	Mục đích vay	unknown	134	0.090
8	Giới tính/đồng vay	male	42346	28.480
9	Giới tính/đồng vay	joint	41399	27.850
10	Giới tính/đồng vay	sex not available	37659	25.330
11	Giới tính/đồng vay	female	27266	18.340

Nhận xét: type1 chiếm 76,12% số khoản vay; hai nhóm mục đích p3 và p4 chiếm tổng cộng 74,48%. Mục đích vay có 134 hồ sơ unknown. Về giới tính/đồng vay, sex not available chiếm 25,33%, tức khoảng một phần tư hồ sơ không có thông tin giới tính.

Kết luận: Cơ cấu khoản vay không đồng đều và biến giới tính có tỷ lệ không xác định đáng kể, nên cần xét tỷ lệ trên từng nhóm khi phân tích tình trạng vỡ nợ và không diễn giải nhóm sex not available như một nhóm khách hàng thực.

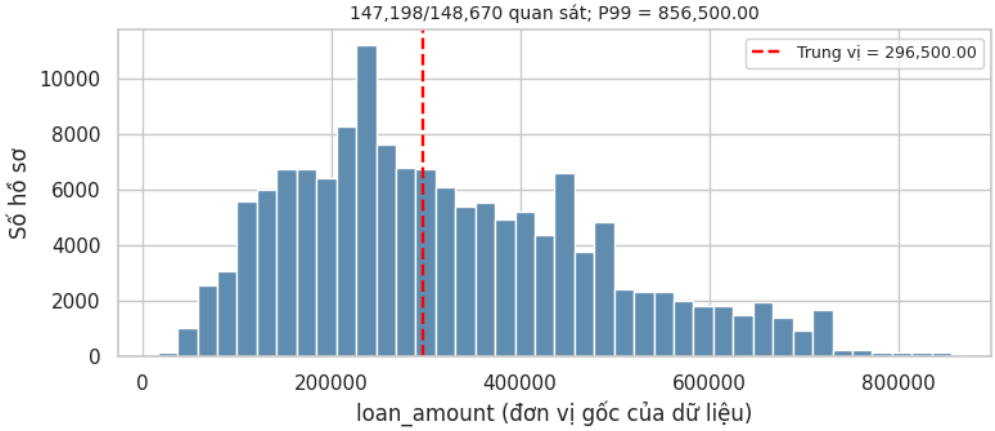
3.2. Phân tích phân phối từng biến (Univariate Analysis)

3.2.1. Phân phối loan_amount

```
# Hình 3.2: Chỉ phóng vùng đến P99, không loại hồ sơ khỏi dữ liệu.
fig, ax = plt.subplots(figsize=(8, 4))
ve_hist(ax, "loan_amount", bins=40, p99=True)
ax.set_xlabel("loan_amount (đơn vị gốc của dữ liệu)")
fig.suptitle("Hình 3.2. Phân phối quy mô khoản vay", fontsize=12)
plt.tight_layout()
print(f"Độ lệch (skewness) toàn bộ: {eda['loan_amount'].skew():.2f}")
```

Độ lệch (skewness) toàn bộ: 1.67

Hình 3.2. Phân phối quy mô khoản vay



Nhận xét: Phân phối loan_amount lệch phải (skewness = 1,67), với trung vị 296.500 thấp hơn trung bình 331.117,74.

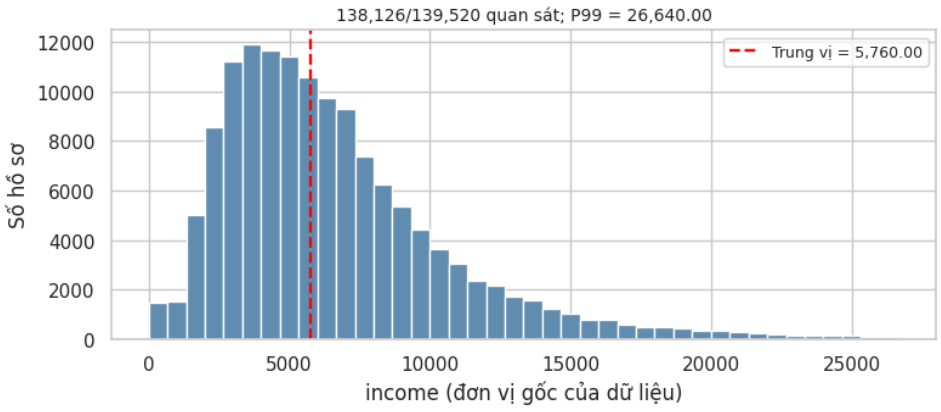
Kết luận: Một số khoản vay lớn kéo đuôi phân phối; biểu đồ chỉ phóng vùng đến P99, không loại bỏ các hồ sơ lớn.

3.2.2. Phân phối income

```
# Hình 3.3: Bỏ NaN riêng khi vẽ; không đổi các khoản income = 0.
fig, ax = plt.subplots(figsize=(8, 4))
ve_hist(ax, "income", bins=40, p99=True)
ax.set_xlabel("income (đơn vị gốc của dữ liệu)")
fig.suptitle("Hình 3.3. Phân phối thu nhập", fontsize=12)
plt.tight_layout()
print(f"Độ lệch (skewness) trên N hợp lệ: {eda['income'].skew():.2f}")
```

Độ lệch (skewness) trên N hợp lệ: 17.31

Hình 3.3. Phân phối thu nhập



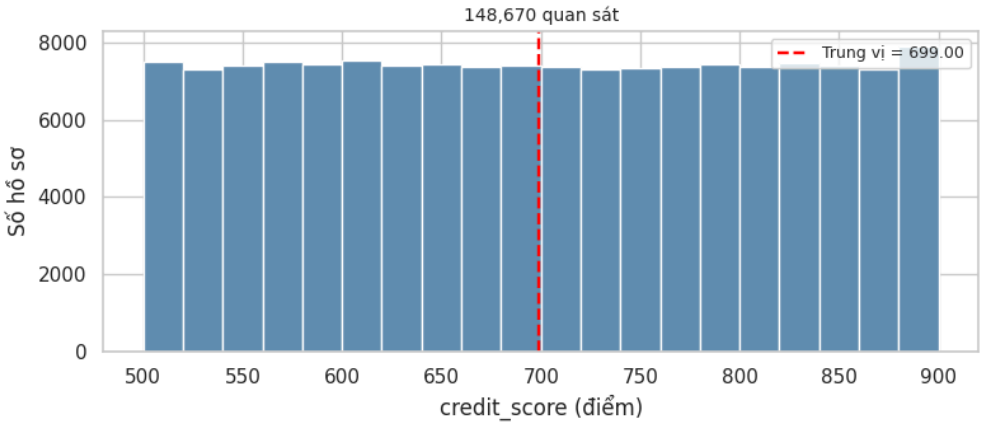
Nhận xét: income lệch phải rất mạnh (skewness = 17,31); trung vị 5.760 trong khi giá trị lớn nhất đạt 578.580, gấp khoảng 22 lần P99 (26.640).

Kết luận: Trung vị phù hợp hơn trung bình để phản ánh thu nhập điển hình. Các giá trị bằng 0 (1.260 hồ sơ) vẫn được giữ để phân tích riêng, vì ở 3.4.2 nhóm này có tỷ lệ status = 1 bất thường.

3.2.3. Phân phối Credit_Score

```
# Hình 3.4: Hiển thị toàn bộ dải 500–900, không cắt ngưỡng P99.
fig, ax = plt.subplots(figsize=(8, 4))
ve_hist(ax, "credit_score", bins=20)
ax.set_xlabel("credit_score (điểm)")
fig.suptitle("Hình 3.4. Phân phối điểm tín dụng", fontsize=12)
plt.tight_layout()
plt.show()
print("Tần suất theo nhóm điểm đã tạo ở Chương 2:")
display(eda['credit_score_band'].value_counts(sort=False).to_frame("Số hồ sơ"))
```

Hình 3.4. Phân phối điểm tín dụng



Tần suất theo nhóm điểm đã tạo ở Chương 2:

	Số hồ sơ
credit_score_band	
500–599	37190
600–699	37200

700–799	36811
800–900	37469

.

Nhận xét: Bốn khoảng điểm tín dụng có quy mô gần bằng nhau (36.811 - 37.469 hồ sơ/nhóm, mỗi nhóm khoảng 25%), với trung vị chung 699.

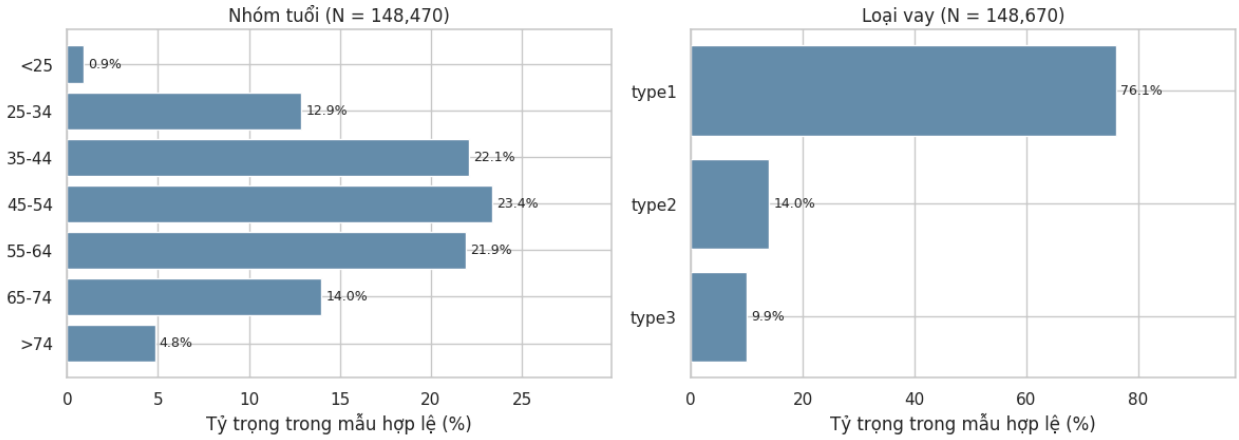
Kết luận: Phân phối gần như phẳng trong khoảng 500–900, khác với điểm tín dụng thực tế thường có dạng hình chuông. Đây là dấu hiệu dữ liệu có thể là mô phỏng hoặc đã ẩn danh. Phân phối đơn biến này chưa cho biết điểm tín dụng có phân biệt được status hay không; vấn đề này được kiểm tra ở 3.4.3 và 3.5 (H3)

3.2.4. Phân phối theo nhóm tuổi và loại khoản vay

```
# Hình 3.5: age=unknown không phải nhóm tuổi nên loại khỏi mẫu số biểu đồ
tuổi.
age_order = ["<25", "25-34", "35-44", "45-54", "55-64", "65-74", ">74"]
age_n = eda.loc[eda['age'].isin(age_order),
'age'].value_counts().reindex(age_order, fill_value=0)
loan_n = eda['loan_type'].value_counts()

fig, axes = plt.subplots(1, 2, figsize=(12, 4.8))
for ax, counts, title in [
    (axes[0], age_n, f"Nhóm tuổi (N = {age_n.sum():,})"),
    (axes[1], loan_n, f"Loại vay (N = {loan_n.sum():,})")]:
    percentage = counts.div(counts.sum()).mul(100)
    bars = ax.barh(counts.index, percentage, color='#668dad')
    ax.bar_label(bars, fmt="%.1f%%", padding=3, fontsize=9)
    ax.set_xlim(0, percentage.max() * 1.28)
    ax.invert_yaxis()
    ax.set_xlabel("Tỷ trọng trong mẫu hợp lệ (%)")
    ax.set_title(title)
fig.suptitle("Hình 3.5. Cơ cấu theo tuổi và loại khoản vay", fontsize=12)
plt.tight_layout()
plt.show()
print("Hồ sơ age=unknown (không đưa vào biểu đồ tuổi):",
eda['age'].eq('unknown').sum())
```

Hình 3.5. Cơ cấu theo tuổi và loại khoản vay



Hồ sơ age=unknown (không đưa vào biểu đồ tuổi): 200

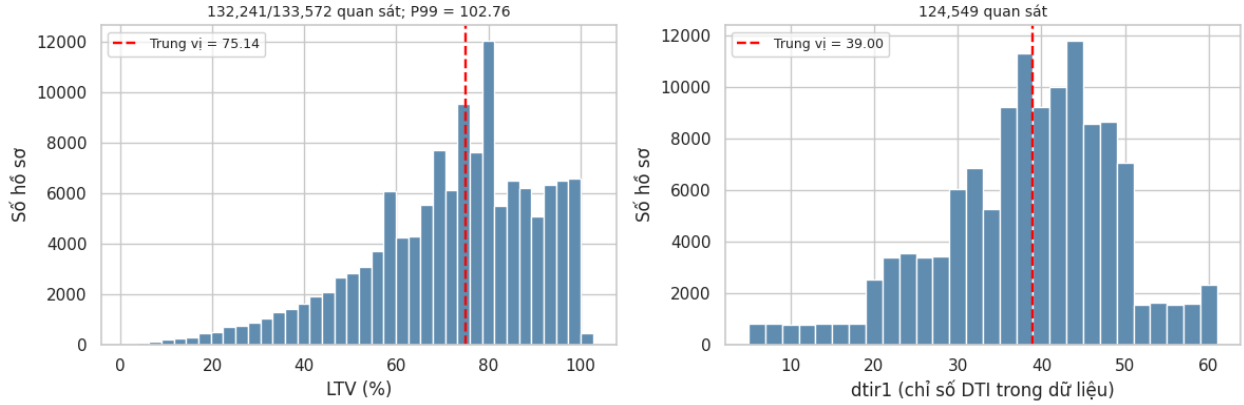
Nhận xét: Nhóm tuổi 45–54 có nhiều hồ sơ nhất (34.720); ba nhóm 35–64 tuổi chiếm 67,4% số hồ sơ có tuổi, trong khi nhóm dưới 25 tuổi chỉ chiếm 0,9%. type1 chiếm 76,12% khoản vay. Có 200 hồ sơ age = unknown được loại riêng khỏi biểu đồ tuổi.

Kết luận: Danh mục tập trung vào người vay trung niên; cần phân biệt sự phổ biến của một nhóm với tỷ lệ vỡ nợ của nhóm đó.

3.2.5. Phân phối các chỉ số LTV và DTI

```
# Hình 3.6: LTV chỉ phóng đến P99 do có 6 giá trị > 1.000%; DTI hiện toàn bộ.
fig, axes = plt.subplots(1, 2, figsize=(12, 4.5))
ve_hist(axes[0], 'ltv', bins=38, p99=True)
ve_hist(axes[1], 'dtir1', bins=28)
axes[0].set_xlabel("LTV (%)")
axes[1].set_xlabel("dtir1 (chỉ số DTI trong dữ liệu)")
fig.suptitle("Hình 3.6. Phân phối LTV và DTI", fontsize=12)
plt.tight_layout()
plt.show()
print(f"LTV > 1.000% (giữ nguyên): {eda['ltv'].gt(1000).sum():,} hồ sơ")
print("Tỷ lệ thiếu LTV / DTI:",
      f"{eda['ltv'].isna().mean():.2%} / {eda['dtir1'].isna().mean():.2%}")
```

Hình 3.6. Phân phối LTV và DTI



LTV > 1.000% (giữ nguyên): 6 hồ sơ
Tỷ lệ thiếu LTV / DTI: 10.16% / 16.22%

Nhận xét: LTV có trung vị 75,14%, DTI có trung vị 39; tỷ lệ thiếu tương ứng 10,16% và 16,22%. Có 1.799 hồ sơ (1,35% mẫu có LTV) với LTV trên 100%, tức khoản vay lớn hơn giá trị tài sản. Sáu hồ sơ LTV trên 1.000% đều có giá trị tài sản bằng 8.000 và thiếu thu nhập, nên nghi là lỗi nhập liệu. DTI có giá trị lớn nhất chỉ 61 nên bị chặn ở phía trên.

Kết luận: Biểu đồ LTV phóng vùng đến P99 để dễ quan sát nhưng vẫn giữ các giá trị cực trị trong dữ liệu; nhóm LTV trên 100% là nhóm cần theo dõi riêng.

3.3. Phân tích chất lượng dữ liệu theo trạng thái vỡ nợ

3.3.1. So sánh Missing Values giữa hai nhóm Status

```
# 7 biến số còn NaN; 2 biến phân loại thiếu gốc đã được gán nhãn 'unknown'
ở Chương 2.
missing_vars = ['interest_rate_spread', 'rate_of_interest',
'upfront_charges',
                'property_value', 'ltv', 'dtir1', 'income']
assert all(eda[c].isna().any() for c in missing_vars)

missing_flags = eda[missing_vars].isna().copy()
for col in ['age', 'submission_of_application']:
    # Phân biệt thiếu gốc đã chuyển thành 'unknown' với NaN còn tồn tại.
    assert eda[col].eq('unknown').sum() == df_raw[col].isna().sum()
    missing_flags[f'{col} (unknown)'] = eda[col].eq('unknown')

miss0 = missing_flags.loc[eda.status.eq(0)].mean() * 100
```

```
miss1 = missing_flags.loc[eda.status.eq(1)].mean() * 100
bang_33 = pd.DataFrame({'Thiếu | status=0 (%)': miss0,
                        'Thiếu | status=1 (%)': miss1,
                        'Chênh lệch (đpt; 1-0)': miss1 - miss0})
print('Bảng 3.3. Missing theo status (7 biến còn NaN, 2 biến thiếu gốc đã gán unknown):')
display(bang_33.round(2))
#Lưu ý: age và submission_of_application không còn là NaN sau làm sạch;' hai dòng cuối phản ánh thiếu dữ liệu gốc, không phải nhóm tuổi/kênh nộp thực.'
```

Bảng 3.3. Missing theo status (7 biến còn NaN, 2 biến thiếu gốc đã gán unknown):

	Thiếu | status=0 (%)	Thiếu | status=1 (%)	Chênh lệch (đpt; 1−0)
interest_rate_spread	0.000	100.000	100.000
rate_of_interest	0.000	99.450	99.450
upfront_charges	2.820	99.580	96.770
property_value	0.000	41.200	41.200
ltv	0.000	41.200	41.200
dtir1	6.970	44.520	37.540
income	7.060	3.380	-3.680
age (unknown)	0.000	0.550	0.550
submission_of_application (unknown)	0.000	0.550	0.550

Nhận xét: interest_rate_spread thiếu ở 100% hồ sơ status = 1 nhưng không thiếu ở nhóm status = 0; LTV thiếu 41,20% ở nhóm 1 so với 0% ở nhóm 0. Thu nhập lại thiếu nhiều hơn ở nhóm 0 (7,06% so với 3,38%).

Kết luận: Dữ liệu thiếu có liên hệ rõ với status, không phải thiếu ngẫu nhiên. Ba biến lãi suất, chênh lệch lãi suất và phí ban đầu gần như xác định nhãn, nên là dấu hiệu rò rỉ thông tin; chỉ phân tích hồ sơ đầy đủ sẽ gây thiên lệch.

3.3.2. Phân tích sự khác biệt về mẫu quan sát

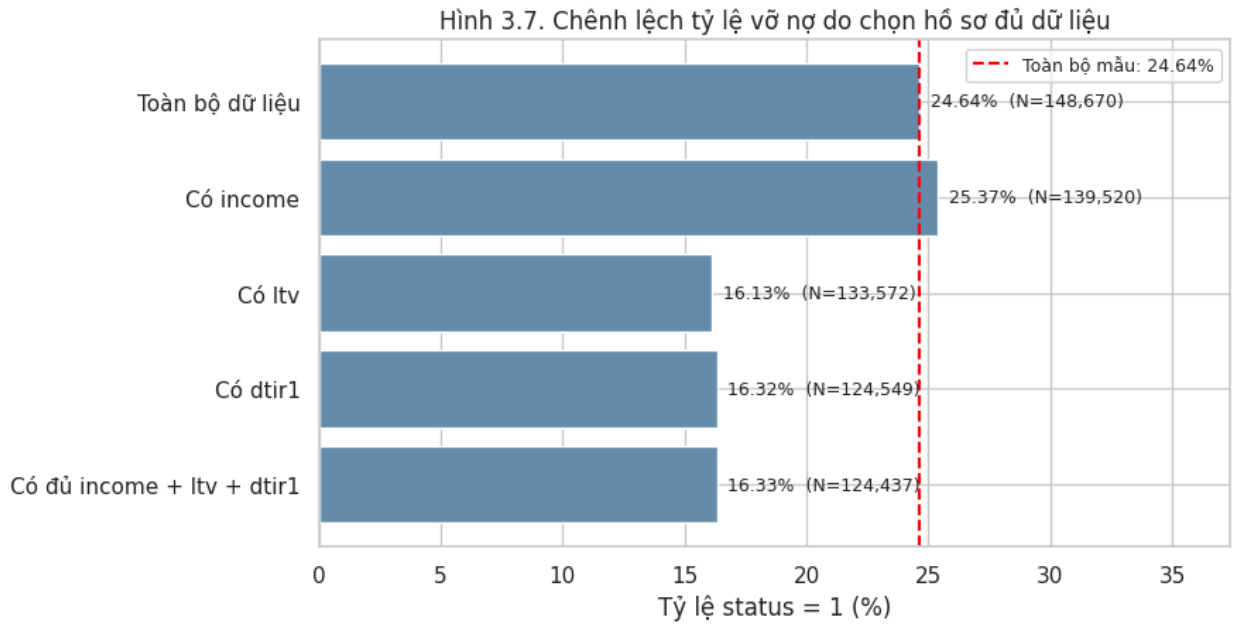
```
# Không xóa dữ liệu: mỗi mask chỉ dùng tính chỉ số trên một tập con.
mau_day_du = {
   'Toàn bộ dữ liệu': pd.Series(True, index=eda.index),
   'Có income': eda['income'].notna(),
   'Có ltv': eda['ltv'].notna(),
   'Có dtir1': eda['dtir1'].notna(),
   'Có đủ income + ltv + dtir1': eda[['income', 'ltv',
'dtir1']].notna().all(axis=1)
}
nen_chung = eda.status.mean() * 100
bang_mau = pd.DataFrame([
   {'Mẫu': name, 'N giữ lại': int(mask.sum()), 'Tỷ lệ giữ lại (%)': 100 *
mask.mean(),
    'Số status=1': int(eda.loc[mask, 'status'].sum()),
    'Status=1 trong mẫu (%)': 100 * eda.loc[mask, 'status'].mean(),
    'Lệch so với toàn bộ (đpt)': 100 * eda.loc[mask, 'status'].mean() -
nen_chung}
   for name, mask in mau_day_du.items()
]).set_index('Mẫu')
display(bang_mau.round(2))
```

Mẫu	N giữ lại	Tỷ lệ giữ lại (%)	Số status=1	Status=1 trong mẫu (%)	Lệch so với toàn bộ (đpt)
Toàn bộ dữ liệu	148670	100.000	36639	24.640	0.000
Có income	139520	93.850	35400	25.370	0.730
Có ltv	133572	89.840	21543	16.130	-8.520
Có dtir1	124549	83.780	20329	16.320	-8.320
Có đủ income + ltv + dtir1	124437	83.700	20319	16.330	-8.320

Nhận xét: Tỷ lệ status = 1 là 24,64% trên toàn bộ mẫu, nhưng còn 16,13% trong mẫu có LTV và 16,33% trong mẫu đủ thu nhập, LTV và DTI (giảm khoảng 8,3–8,5 điểm phần trăm).

Kết luận: Chọn mẫu chỉ gồm hồ sơ đủ dữ liệu làm thay đổi đáng kể cơ cấu kết quả, các tỷ lệ không nên so sánh khi bỏ qua mẫu số.

```
# Hình 3.7: chỉ so tỷ lệ trên các mẫu quan sát khác nhau, kèm N giữ lại.
fig, ax = plt.subplots(figsize=(9, 4.7))
vals = bang_mau['Status=1 trong mẫu (%)']
bars = ax.barh(vals.index, vals, color='#668dad')
ax.axvline(nen_chung, color='red', ls='--', lw=1.5,
           label=f'Toàn bộ mẫu: {nen_chung:.2f}%')
for bar, pct, n in zip(bars, vals, bang_mau['N giữ lại']):
   ax.text(pct + .45, bar.get_y() + bar.get_height()/2,
            f'{pct:.2f}%  (N={n:,})', va='center', fontsize=9)
ax.set_xlim(0, vals.max() + 12)
ax.invert_yaxis()
ax.set_xlabel('Tỷ lệ status = 1 (%)')
ax.set_title('Hình 3.7. Chênh lệch tỷ lệ vỡ nợ do chọn hồ sơ đủ dữ liệu')
ax.legend(fontsize=9)
plt.tight_layout()
plt.show()
print('Tuổi không xác định (age=unknown):',
int(eda.age.eq('unknown').sum()),
     '| status=1:', int(eda.loc[eda.age.eq('unknown'), 'status'].sum()))
# Đối chiếu nguồn gốc thiếu LTV/property_value theo credit_type (không sửa
dữ liệu).
nguon_thieu = pd.crosstab(eda['credit_type'],
eda['ltv'].isna()).reindex(columns=[False, True], fill_value=0)
nguon_thieu.columns = ['LTV có dữ liệu', 'LTV thiếu']
nguon_thieu['Tỷ lệ thiếu LTV (%)'] = (100 * nguon_thieu['LTV thiếu'] /
nguon_thieu.sum(axis=1))
print('Bảng 3.4a. Tình trạng thiếu LTV theo credit_type:')
display(nguon_thieu.round(2))
print(f"Trong {int(eda.ltv.isna().sum()):,} hồ sơ thiếu LTV, "
     f"có {int((eda.credit_type.eq('equi') & eda.ltv.isna()).sum()):,} hồ
sơ loại equi.")
```



Tuổi không xác định (age=unknown): 200 | status=1: 200

Bảng 3.4a. Tình trạng thiếu LTV theo credit_type:

	LTV có dữ liệu	LTV thiếu	Tỷ lệ thiếu LTV (%)
credit_type			
cib	48151	1	0.000
crif	43900	1	0.000
equi	202	15096	98.680
exp	41319	0	0.000

Trong 15,098 hồ sơ thiếu LTV, có 15,096 hồ sơ loại equi.

```
# Đối chiếu cơ cấu mẫu: sự thiếu LTV gần như loại nhóm EQUI khỏi phân tích
LTV.
equi = eda['credit_type'].eq('equi')
co_ltv = eda['ltv'].notna()
bang_doi_chieu_equi = pd.DataFrame([
   {'Mẫu': ten, 'N': int(mask.sum()), 'Số status=1': int(eda.loc[mask,
'status'].sum()),
    'Tỷ lệ status=1 (%)': 100 * eda.loc[mask, 'status'].mean()}
```

```
   for ten, mask in [('Toàn bộ dữ liệu', pd.Series(True,
index=eda.index)),
                     ('Không gồm EQUI', ~equi),
                     ('Có dữ liệu LTV', co_ltv)]
]).set_index('Mẫu')
print('Bảng 3.4b. Đối chiếu tỷ lệ status=1 và cơ cấu EQUI khi chọn mẫu:')
display(bang_doi_chieu_equi.round(2))
print(f"EQUI: {equi.sum():,} hồ sơ, {int(eda.loc[equi, 'status'].sum()):,}
status=1; "
     f"chiếm {100 * (equi & eda.status.eq(1)).sum() /
eda.status.sum():.2f}% "
     'tổng số status=1.')
print(f"EQUI chiếm {(equi & ~co_ltv).sum():,}/{(~co_ltv).sum():,} "
     f"({100*(equi & ~co_ltv).sum()/(~co_ltv).sum():.2f}%) hồ sơ thiếu
LTV.")
```

Bảng 3.4b. Đối chiếu tỷ lệ status=1 và cơ cấu EQUI khi chọn mẫu:

	N	Số status=1	Tỷ lệ status=1 (%)
Mẫu			
Toàn bộ dữ liệu	148670	36639	24.640
Không gồm EQUI	133372	21342	16.000
Có dữ liệu LTV	133572	21543	16.130

EQUI: 15,298 hồ sơ, 15,297 status=1; chiếm 41.75% tổng số status=1.
EQUI chiếm 15,096/15,098 (99.99%) hồ sơ thiếu LTV.

Nhận xét:
Tỷ lệ status=1 trong mẫu có LTV gần tỷ lệ khi bỏ EQUI; sự giảm so với toàn mẫu chủ yếu phản ánh thay đổi cơ cấu credit_type, không chứng minh LTV là nguyên nhân làm thay đổi tình trạng vỡ nợ.
Trong 15.098 hồ sơ thiếu LTV có 15.096 hồ sơ thuộc `EQUI` (99,99%); nhóm `EQUI` có 15.297/15.298 hồ sơ mang `status = 1`. Khi bỏ `EQUI`, tỷ lệ `status = 1` còn 16,00%, gần với 16,13% ở mẫu có LTV.

Kết luận: Chênh lệch tỷ lệ chủ yếu gắn với thay đổi cơ cấu `credit_type`, không chứng minh LTV gây ra vỡ nợ. Nhóm EQUI gần như 100% vỡ nợ là bất thường, cần xác minh định nghĩa biến trước khi dùng.

3.3.3. Ý nghĩa đối với kết quả phân tích

Phát hiện: Dữ liệu thiếu không ngẫu nhiên mà gắn chặt với status (Bảng 3.3).

- interest_rate_spread thiếu ở 100% hồ sơ status = 1 và gần như 0% ở status = 0
- rate_of_interest và upfront_charges thiếu ở hơn 99% nhóm 1.
- dtir1 thiếu 44,52% ở nhóm 1 so với 6,97% ở nhóm 0
- LTV thiếu 41,20% ở nhóm 1 so với gần 0% ở nhóm 0
- income thiếu nhiều hơn ở nhóm 0 (7,06% so với 3,38%).

Tác động 1: Lệch cơ cấu mẫu

Nếu chỉ giữ hồ sơ có LTV, tỷ lệ status = 1 giảm từ 24,64% (148.670 hồ sơ) xuống 16,13% (133.572 hồ sơ). Lý do chủ yếu là nhóm credit_type = EQUI: nhóm này có 15.297/15.298 hồ sơ status = 1 (chiếm 41,75% tổng số hồ sơ nhóm 1) và chiếm 15.096/15.098 hồ sơ thiếu LTV. Khi bỏ EQUI, tỷ lệ còn 16,00%, gần bằng 16,13%. Như vậy mức giảm do thay đổi cơ cấu mẫu, không phải bằng chứng LTV ảnh hưởng đến vỡ nợ.

Tác động 2: Nguy cơ rò rỉ thông tin

Ba biến lãi suất, chênh lệch lãi suất và phí ban đầu gần như báo trước nhãn nên không được dùng để giải thích hay dự báo, và Chương 3 không phân tích chúng theo status.

Bài học:

- Mọi tỷ lệ phải ghi rõ số quan sát hợp lệ và mẫu số
- Kết quả về LTV và DTI chỉ đúng cho hồ sơ có dữ liệu, trên thực tế gần như không gồm EQUI
- Không điền hay coi giá trị thiếu là 0 chỉ để vẽ biểu đồ.

.3.4. Phân tích mối quan hệ giữa các biến và tình trạng vỡ nợ

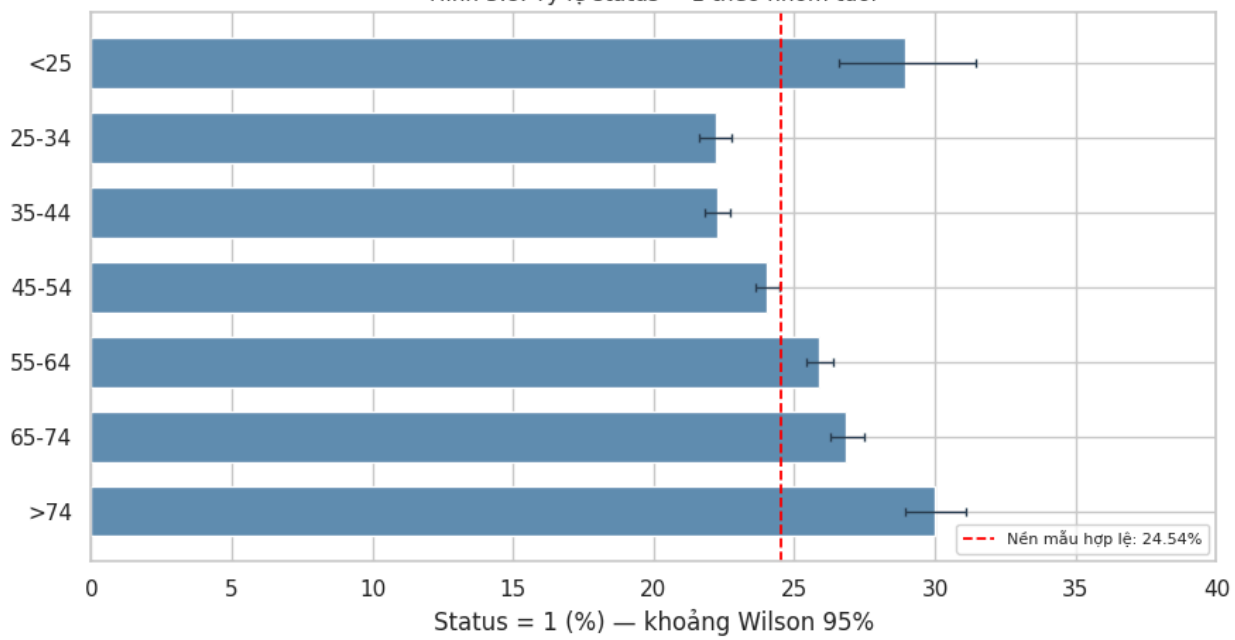
3.4.1. Tỷ lệ vỡ nợ theo nhóm tuổi

```
tuoi_hop_le = eda['age'].isin(age_order)
bang_tuoi = bang_ty_le(eda.loc[tuoi_hop_le, 'age'], age_order)
display(bang_tuoi.round(2))
fig, ax = plt.subplots(figsize=(9, 5))
ve_ty_le(ax, bang_tuoi, 100*eda.loc[tuoi_hop_le, 'status'].mean(),
         'Hình 3.8. Tỷ lệ status = 1 theo nhóm tuổi')
```

```
plt.tight_layout(); plt.show()
```

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
<25	1337	387	28.950	26.580	31.430
25-34	19142	4248	22.190	21.610	22.790
35-44	32818	7309	22.270	21.820	22.720
45-54	34720	8349	24.050	23.600	24.500
55-64	32534	8422	25.890	25.410	26.370
65-74	20744	5571	26.860	26.260	27.460
>74	7175	2153	30.010	28.960	31.080

Hình 3.8. Tỷ lệ status = 1 theo nhóm tuổi



Nhận xét: Tỷ lệ status = 1 thấp nhất ở nhóm 25–34 tuổi (22,19%) và cao nhất ở nhóm trên 74 tuổi (30,01%), chênh khoảng 7,8 điểm phần trăm. Hai nhóm 25–34 và 35–44 có khoảng tin cậy chồng nhau nên không khác biệt; tỷ lệ chỉ tăng đều từ 45 tuổi trở lên. Nhóm dưới 25 tuổi đạt 28,95% nhưng chỉ có 1.337 hồ sơ.

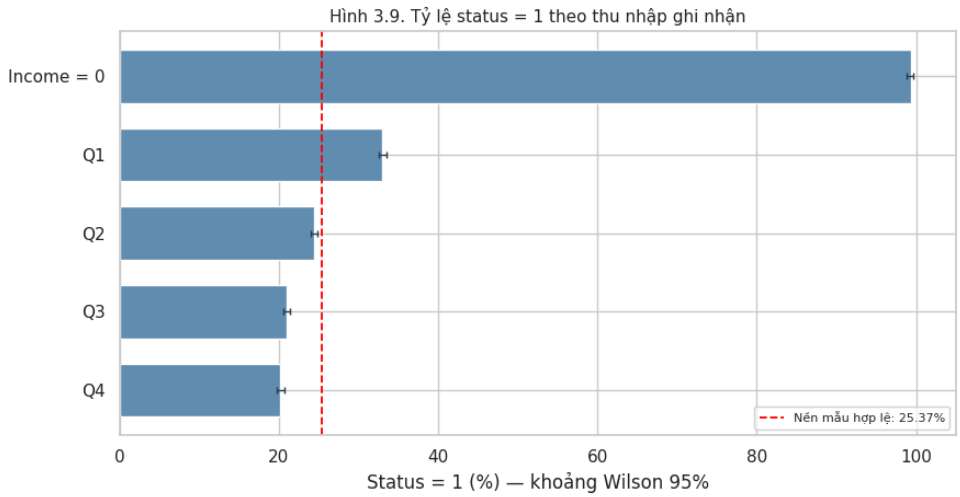
Kết luận: Tuổi có liên hệ nhưng yếu (Cramér's V = 0,050 ở 3.5); cần xét cỡ mẫu và không suy ra tuổi là nguyên nhân gây vỡ nợ.

3.4.2. Tỷ lệ vỡ nợ theo thu nhập

```
# Q1-Q4 chỉ trên income > 0; giữ nhóm income = 0 riêng, không gộp với Q1.
thu_nhap = pd.Series(pd.NA, index=eda.index, dtype='string')
co_thu_nhap = eda['income'].gt(0)
thu_nhap.loc[co_thu_nhap] = pd.qcut(eda.loc[co_thu_nhap, 'income'], 4,
                                    labels=['Q1', 'Q2', 'Q3',
'Q4']).astype('string')
thu_nhap.loc[eda['income'].eq(0)] = 'Income = 0'
thu_tu_income = ['Income = 0', 'Q1', 'Q2', 'Q3', 'Q4']
bang_income = bang_ty_le(thu_nhap, thu_tu_income)
nguong_income = pd.qcut(eda.loc[co_thu_nhap, 'income'], 4,
retbins=True)[1]
print('Các mốc tứ phân vị thu nhập dương:', [f'{x:,.0f}' for x in
nguong_income])
print('Mẫu income hợp lệ:', int(eda.income.notna().sum()), '| thiếu:',
int(eda.income.isna().sum()))
display(bang_income.round(2))
fig, ax = plt.subplots(figsize=(9, 4.8))
ve_ty_le(ax, bang_income, 100*eda.loc[eda.income.notna(),
'status'].mean(),
         'Hình 3.9. Tỷ lệ status = 1 theo thu nhập ghi nhận')
plt.tight_layout(); plt.show()
```

Các mốc tứ phân vị thu nhập dương: ['60', '3,780', '5,760', '8,580', '578,580']
Mẫu income hợp lệ: 139520 | thiếu: 9150

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
Income = 0	1260	1252	99.370	98.750	99.680
Q1	35075	11568	32.980	32.490	33.470
Q2	34293	8382	24.440	23.990	24.900
Q3	34791	7303	20.990	20.570	21.420
Q4	34101	6895	20.220	19.800	20.650



Nhận xét: Trong các hồ sơ thu nhập dương, tỷ lệ status = 1 giảm từ 32,98% (Q1) xuống 20,22% (Q4), giảm rõ từ Q1 đến Q3 rồi gần như đi ngang (20,99% → 20,22%). Riêng 1.260 hồ sơ income = 0 có tỷ lệ lên đến 99,37% (1.252 hồ sơ).

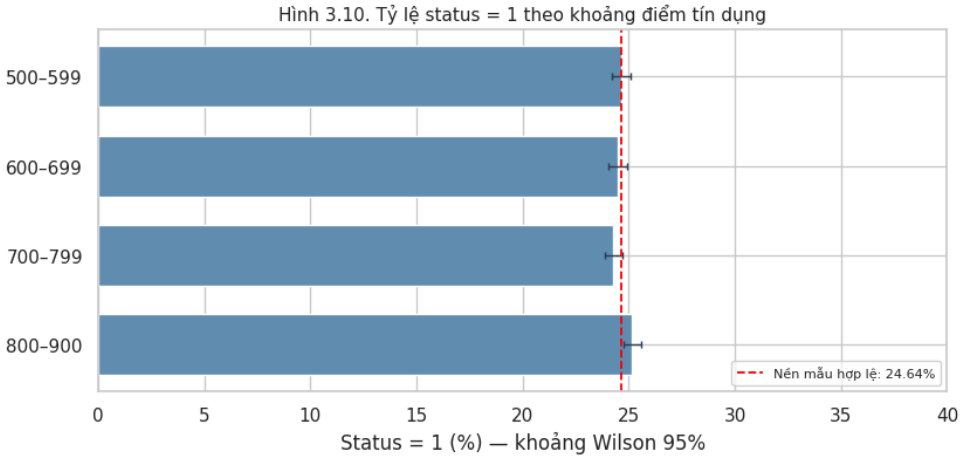
Kết luận: Thu nhập thấp liên hệ với tỷ lệ nhóm 1 cao hơn. Nhóm income = 0 rất bất thường, có thể là cách mã hóa của hồ sơ lỗi hoặc vỡ nợ chứ không phải thu nhập thật, nên phải xem riêng, không gộp vào Q1.

3.4.3. Điểm tín dụng và tình trạng vỡ nợ

```
# Credit score đủ dữ liệu; so sánh tỷ lệ status=1 ở bốn khoảng điểm
score_order = ['500-599', '600-699', '700-799', '800-900']
bang_score = bang_ty_le(eda['credit_score_band'], score_order)
display(bang_score.round(2))
fig, ax = plt.subplots(figsize=(8.5, 4.2))
ve_ty_le(ax, bang_score, 100*eda.status.mean(),
         'Hình 3.10. Tỷ lệ status = 1 theo khoảng điểm tín dụng')
plt.tight_layout(); plt.show()
```

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
500–599	37190	9160	24.630	24.200	25.070
600–699	37200	9108	24.480	24.050	24.920
700–799	36811	8940	24.290	23.850	24.730

800–900	37469	9431	25.170	24.730	25.610



Nhận xét: Tỷ lệ status = 1 ở bốn nhóm điểm tín dụng chỉ dao động 24,29%–25,17%, chênh tối đa 0,88 điểm phần trăm; các khoảng tin cậy chồng nhau và nhóm điểm cao nhất (800–900) lại có tỷ lệ cao nhất.

Kết luận: Điểm tín dụng không cho thấy khả năng phân biệt hai trạng thái, trái với kỳ vọng lý thuyết. Cùng với phân phối gần phẳng ở 3.2.3, điều này cho thấy biến này ít giá trị trong bộ dữ liệu hiện tại; kết quả kiểm định ở 3.5 (H3) sẽ xác nhận thêm.

3.4.4. Quy mô khoản vay và tình trạng vỡ nợ

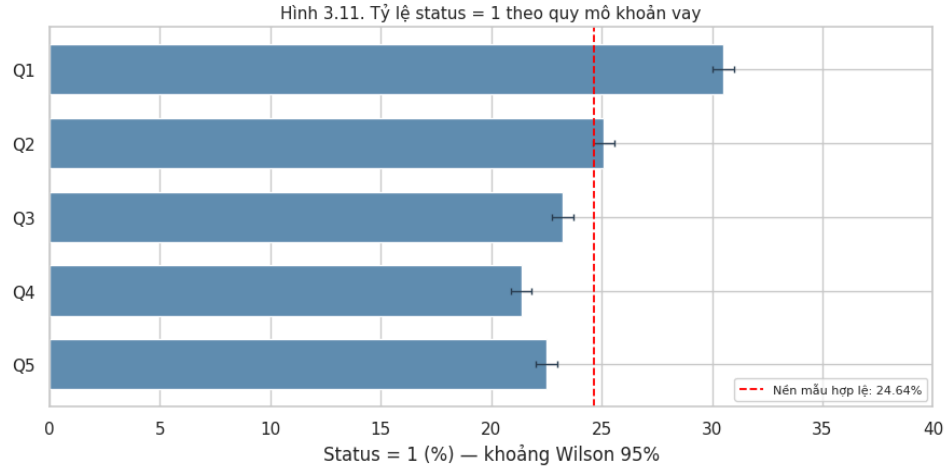
```
# loan_amount đủ dữ liệu: chia năm phân vị
nhom_vay = pd.qcut(eda['loan_amount'], 5, labels=['Q1', 'Q2', 'Q3', 'Q4',
'Q5'])
nguong_vay = pd.qcut(eda['loan_amount'], 5, retbins=True)[1]
print('Các mốc phân vị loan_amount:', [f'{x:,.0f}' for x in nguong_vay])
bang_vay = bang_ty_le(nhom_vay, ['Q1', 'Q2', 'Q3', 'Q4', 'Q5'])
display(bang_vay.round(2))
fig, ax = plt.subplots(figsize=(9, 4.6))
ve_ty_le(ax, bang_vay, 100*eda.status.mean(),
         'Hình 3.11. Tỷ lệ status = 1 theo quy mô khoản vay')
plt.tight_layout(); plt.show()
```

Các mốc phân vị loan_amount: ['16,500', '176,500', '256,500', '346,500', '476,500', '3,576,500']

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)

nhom					
Q1	31920	9737	30.500	30.000	31.010
Q2	29910	7503	25.090	24.600	25.580
Q3	28557	6633	23.230	22.740	23.720
Q4	30419	6499	21.360	20.910	21.830
Q5	27864	6267	22.490	22.000	22.990

Hình 3.11. Tỷ lệ status = 1 theo quy mô khoản vay



Nhận xét: Nhóm khoản vay nhỏ nhất Q1 (đến 176.500) có tỷ lệ status = 1 là 30,50%, cao hơn Q4 (21,36%); Q5 tăng nhẹ lên 22,49%. Mức giảm mạnh nhất nằm ở bước Q1 sang Q2 (5,4 điểm phần trăm).

Kết luận: Mối liên hệ có dạng giảm rồi đi ngang, không tăng đều theo số tiền vay, nên không thể kết luận khoản vay lớn hơn luôn rủi ro hơn. Khoản vay nhỏ thường đi cùng thu nhập thấp (ρ = 0,642 ở 3.6.1) nên hai hiệu ứng này khó tách riêng.

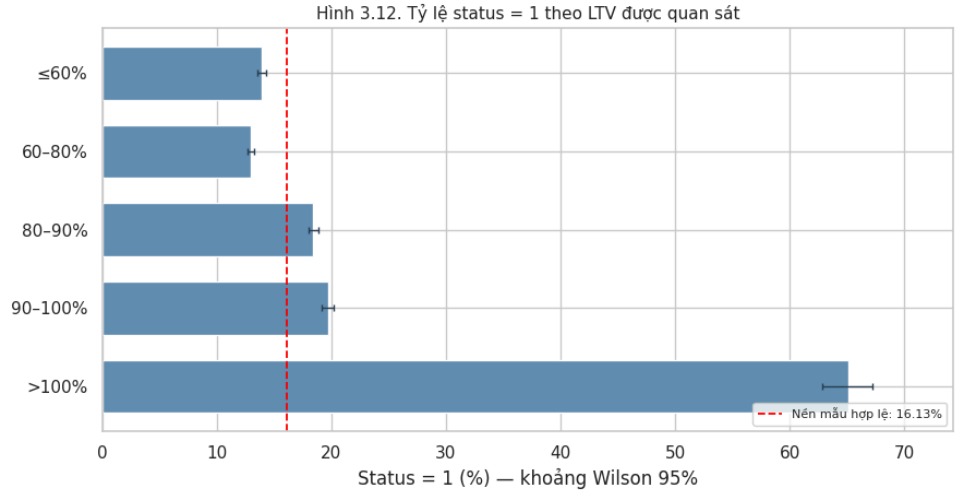
3.4.5. Tỷ lệ LTV và tình trạng vỡ nợ

```
# LTV là tỷ lệ phần trăm theo dữ liệu; loại NaN khỏi mẫu số nhưng giữ mọi
giá trị cực trị.
nhom_ltv = pd.cut(eda['ltv'], [-np.inf, 60, 80, 90, 100, np.inf],
                  labels=['≤60%', '60-80%', '80-90%', '90-100%', '>100%'])
ltv_order = ['≤60%', '60-80%', '80-90%', '90-100%', '>100%']
bang_ltv = bang_ty_le(nhom_ltv, ltv_order)
display(bang_ltv.round(2))
fig, ax = plt.subplots(figsize=(9, 4.8))
ve_ty_le(ax, bang_ltv, 100*eda.loc[eda.ltv.notna(), 'status'].mean(),
```

```
          'Hình 3.12. Tỷ lệ status = 1 theo LTV được quan sát')
plt.tight_layout(); plt.show()

# Kiểm tra độ nhạy riêng nhóm >100% nếu không tính sáu giá trị cực trị
>1000%.
ltv_100_1000 = eda['ltv'].gt(100) & eda['ltv'].le(1000)
print(f'Nhóm 100% < LTV ≤ 1000%: N={ltv_100_1000.sum():,}, '
      f'status=1={eda.loc[ltv_100_1000, "status"].mean():.2%}; '
      f'LTV >1000%: {eda.ltv.gt(1000).sum():,} hồ sơ.')
```

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
≤60%	32565	4534	13.920	13.550	14.300
60–80%	49895	6456	12.940	12.650	13.240
80–90%	26153	4822	18.440	17.970	18.910
90–100%	23160	4560	19.690	19.180	20.210
>100%	1799	1171	65.090	62.860	67.260



Nhóm 100% < LTV ≤ 1000%: N=1,793, status=1=65.25%; LTV >1000%: 6 hồ sơ.

Nhận xét: Nhóm LTV trên 100% có tỷ lệ status = 1 đạt 65,09% (1.799 hồ sơ), cao hơn rõ rệt nhóm LTV 60–80% (12,94%). Nhóm ≤60% (13,92%) không thấp hơn nhóm 60–80%, tức quan

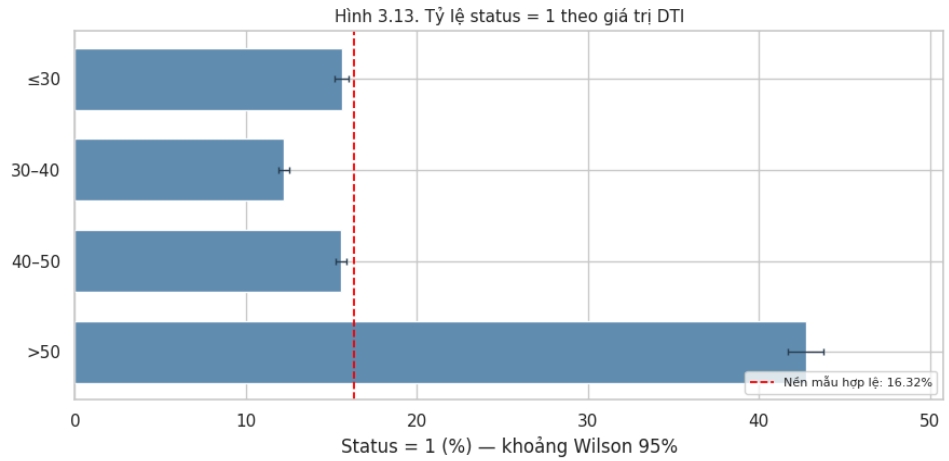
hệ không đơn điệu; bước nhảy chủ yếu nằm ở mốc 100%. Bỏ sáu giá trị LTV trên 1.000% thì tỷ lệ nhóm trên 100% vẫn là 65,25%.

Kết luận: Khi khoản vay vượt giá trị tài sản, rủi ro tăng mạnh. Nhóm này chỉ chiếm 1,35% mẫu có LTV nhưng chứa 5,4% số hồ sơ vỡ nợ trong mẫu đó. Đây là tín hiệu liên hệ trong mẫu có LTV (gần như không gồm EQUI), không phải bằng chứng nhân quả.

3.4.6. DTI và tình trạng vỡ nợ

```
# So sánh phân tầng DTI trên đúng tập có dtir1 quan sát được.
nhom_dti = pd.cut(eda['dtir1'], [-np.inf, 30, 40, 50, np.inf],
                  labels=['≤30', '30-40', '40-50', '>50'])
dti_order = ['≤30', '30-40', '40-50', '>50']
bang_dti = bang_ty_le(nhom_dti, dti_order)
display(bang_dti.round(2))
fig, ax = plt.subplots(figsize=(9, 4.5))
ve_ty_le(ax, bang_dti, 100*eda.loc[eda.dtir1.notna(), 'status'].mean(),
         'Hình 3.13. Tỷ lệ status = 1 theo giá trị DTI')
plt.tight_layout(); plt.show()
```

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
≤30	27970	4364	15.600	15.180	16.030
30–40	41861	5109	12.200	11.890	12.520
40–50	46079	7164	15.550	15.220	15.880
>50	8639	3692	42.740	41.700	43.780



Nhận xét: Nhóm DTI trên 50 có tỷ lệ status = 1 là 42,74%, so với 12,20% ở nhóm DTI 30–40; các nhóm dưới 50 không tăng đều theo DTI (15,60%, 12,20%, 15,55%). Nhóm DTI trên 50 chiếm 6,9% mẫu nhưng chứa 18,2% số hồ sơ vỡ nợ trong mẫu có DTI.

Kết luận: Mốc DTI = 50 là điểm gãy rõ nhất (từ 15,55% lên 42,74%), cần quan tâm khi rà soát danh mục. Kết quả chỉ đại diện cho 124.549 hồ sơ có DTI.

3.4.7. Loại khoản vay và mục đích vay

```
# Bảng: Loại khoản vay và mục đích vay
loan_type_order = ['type1', 'type2', 'type3']
purpose_order = ['p1', 'p2', 'p3', 'p4', 'unknown']
bang_loai_vay = bang_ty_le(eda['loan_type'], loan_type_order)
bang_muc_dich = bang_ty_le(eda['loan_purpose'], purpose_order)
print('Loại khoản vay:'); display(bang_loai_vay.round(2))
print('Mục đích vay:'); display(bang_muc_dich.round(2))

# Hình 3.14: Tỷ lệ status = 1 theo loại và mục đích vay
fig, axes = plt.subplots(1, 2, figsize=(13.5, 4.7))
ve_ty_le(axes[0], bang_loai_vay, 100*eda.status.mean(), 'Loại khoản vay')
ve_ty_le(axes[1], bang_muc_dich, 100*eda.status.mean(), 'Mục đích vay')
fig.suptitle('Hình 3.14. Tỷ lệ status = 1 theo loại và mục đích vay',
fontsize=12)
plt.tight_layout(); plt.show()
```

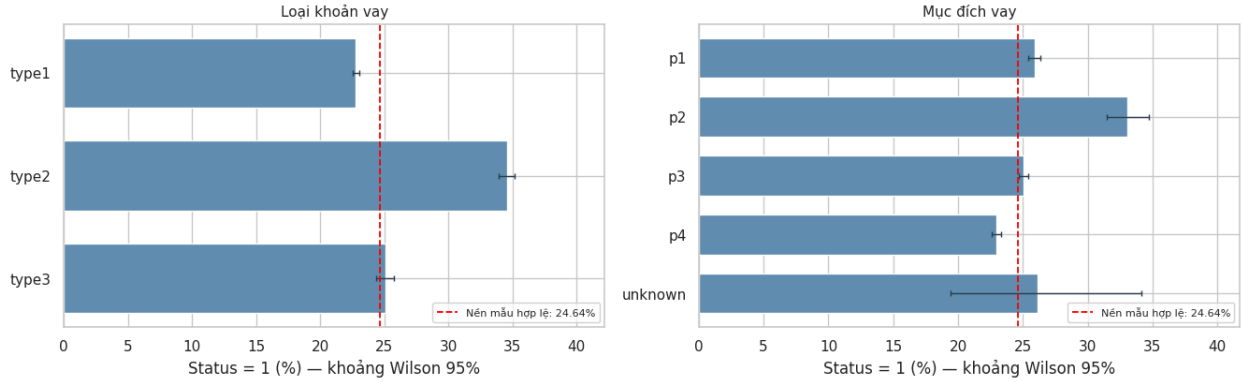
Loại khoản vay:

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
type1	113173	25775	22.770	22.530	23.020
type2	20762	7172	34.540	33.900	35.190
type3	14735	3692	25.060	24.360	25.760

Mục đích vay:

	N	Status=1	Tỷ lệ (%)	CI thấp (%)	CI cao (%)
nhom					
p1	34529	8935	25.880	25.420	26.340
p2	3274	1083	33.080	31.490	34.710
p3	55934	13996	25.020	24.670	25.380
p4	54799	12590	22.970	22.620	23.330
unknown	134	35	26.120	19.420	34.150

Hình 3.14. Tỷ lệ status = 1 theo loại và mục đích vay



Nhận xét: type2 có tỷ lệ status = 1 cao nhất trong ba loại vay (34,54%), cao hơn type1 (22,77%) 11,77 điểm phần trăm; type2 chính là nhóm khoản vay kinh doanh/thương mại và chiếm 13,97% hồ sơ. Theo mục đích, chỉ p2 nổi bật (33,08%, chỉ 3.274 hồ sơ), trong khi p1, p3, p4 chênh nhau nhỏ (22,97%–25,88%); nhóm unknown (134 hồ sơ) có khoảng tin cậy quá rộng để kết luận.

Kết luận: Khoản vay kinh doanh có rủi ro cao hơn khoản vay thông thường, còn mục đích vay ít phân biệt. Không suy ra quan hệ nhân quả.

3.5. Kiểm định các giả thuyết nghiên cứu

```
from scipy.stats import chi2_contingency, mannwhitneyu,
false_discovery_control
from itertools import combinations

# 1. Kiểm định Chi-square và tính Cramér's V
def kiem_chi2(ma, ten, nhom):
    tmp = pd.DataFrame({'nhom': nhom, 'status': eda['status']}).dropna()
    bang = pd.crosstab(tmp['nhom'], tmp['status']).reindex(columns=[0, 1],
fill_value=0
    chi2, p, do_tu_do, expected = chi2_contingency(bang, correction=False)
    assert expected.min() >= 5, f'Ô tần số kỳ vọng nhỏ ở {ma}; cần thay
kiểm định.'
    v = np.sqrt(chi2 / (len(tmp) * min(bang.shape[0]-1, bang.shape[1]-1)))
    return [ma, ten, len(tmp), f'χ²({do_tu_do}) = {chi2:,.1f}', p, f'V =
{v:.3f}', v]

# 2. Kiểm định Mann-Whitney U và tính Cliff's delta
def kiem_mann_whitney(ma, ten, bien):
    mau_1 = eda.loc[eda['status'].eq(1), bien].dropna()
    mau_0 = eda.loc[eda['status'].eq(0), bien].dropna()
    u, p = mannwhitneyu(mau_1, mau_0, alternative='two-sided',
method='asymptotic')
    delta = 2*u / (len(mau_1)*len(mau_0)) - 1
    return [ma, ten, len(mau_1)+len(mau_0), f'U = {u:,.0f}', p,
            f'Cliff δ = {delta:+.3f}', delta]

# 3. Thực hiện 7 kiểm định
kiem_dinh = [
    kiem_chi2('H1a', 'Nhóm tuổi × status',
eda['age'].where(eda['age'].isin(age_order))),
    kiem_chi2('H1b', 'Loại vay × status', eda['loan_type']),
    kiem_mann_whitney('H2', 'Income theo status', 'income'),
    kiem_mann_whitney('H3', 'Credit score theo status', 'credit_score'),
    kiem_chi2('H4', '5 phân vị loan_amount × status', nhom_vay),
    kiem_chi2('H5a', 'Nhóm LTV × status', nhom_ltv),
```

```
    kiem_chi2('H5b', 'Nhóm DTI × status', nhom_dti)
]
ket_qua_35 = pd.DataFrame(kiem_dinh, columns=[
    'Mã', 'Giả thuyết', 'N', 'Thống kê', 'p_thuc', 'Hiệu ứng', 'Hiệu ứng
số'
])
# 4. Hiệu chỉnh FDR bằng Benjamini-Hochberg
ket_qua_35['q_fdr'] = false_discovery_control(
    ket_qua_35['p_thuc'].to_numpy(), method='bh'
)
# 5. Trình bày bảng kết quả.
```

Bảng 3.5. Kết quả 7 phép kiểm định (p=0 do tràn số chỉ biểu thị là p rất nhỏ):

	Mã	Giả thuyết	N	Thống kê	Hiệu ứng	p	q (FDR)	Kết luận (α=5%)
0	H1a	Nhóm tuổi × status	148470	$\chi^2(6) = 374.5$	V = 0.050	8.44e-78	9.85e-78	Có bằng chứng liên hệ
1	H1b	Loại vay × status	148670	$\chi^2(2) = 1,310.0$	V = 0.094	3.52e-285	6.16e-285	Có bằng chứng liên hệ
2	H2	Income theo status	139520	U = 1,502,807,176	Cliff δ = -0.185	<1e-300	<1e-300	Có bằng chứng liên hệ
3	H3	Credit score theo status	148670	U = 2,063,311,078	Cliff δ = +0.005	0.1243	0.1243	Chưa đủ bằng chứng
4	H4	5 phân vị loan_amount × status	148670	$\chi^2(4) = 870.0$	V = 0.076	5.38e-187	7.53e-187	Có bằng chứng liên hệ
5	H5a	Nhóm LTV × status	133572	$\chi^2(4) = 4,000.8$	V = 0.173	<1e-300	<1e-300	Có bằng chứng liên hệ
6	H5b	Nhóm DTI × status	124549	$\chi^2(3) = 4,963.7$	V = 0.200	<1e-300	<1e-300	Có bằng chứng liên hệ

Đối chiếu trung vị:

	income	credit_score
status		
Status = 0	6,000.000	699.000
Status = 1	4,860.000	700.000

Phương pháp: Mức ý nghĩa 5%. Dùng Chi-square cho biến phân loại và Mann–Whitney U cho biến định lượng. P-value được hiệu chỉnh nhiều phép thử bằng Benjamini–Hochberg (FDR) và kết luận theo q < 0,05. Vì mẫu rất lớn nên p-value gần như luôn nhỏ, nên (Cramér's V < 0,10 là rất yếu, 0,10–0,30 là yếu; |Cliff's δ| < 0,147 là không đáng kể, 0,147–0,33 là nhỏ). Với mỗi giả thuyết, H0 là "không có liên hệ với `status`"

Mã	Biến kiểm định	Hiệu ứng	Kết luận
H1a	Nhóm tuổi	V = 0,050 (rất yếu)	Bác bỏ H0. Cao nhất nhóm >74 (30,01%), thấp nhất 25–34 (22,19%).
H1b	Loại vay	V = 0,094 (rất yếu)	Bác bỏ H0. type2 34,54% so với type1 22,77%.
H2	Thu nhập	δ = −0,185 (nhỏ)	Bác bỏ H0. Trung vị 4.860 (nhóm 1) so với 6.000 (nhóm 0). Hiệu ứng nhạy với income = 0 (δ = −0,155 nếu bỏ nhóm này, xem 3.6.5).
H3	Điểm tín dụng	δ = +0,005 (không đáng kể)	**Không bác bỏ H0.** Trung vị 700 so với 699.
H4	Quy mô vay (5 nhóm)	V = 0,076 (rất yếu)	Bác bỏ H0, nhưng không đơn điệu: Q1 30,50% → Q4 21,36% → Q5 22,49%.
H5a	LTV	V = 0,173 (yếu)	Bác bỏ H0. LTV > 100%: 65,09%, so với 12,94% ở nhóm 60–80%.
H5b	DTI	V = 0,200 (yếu)	Bác bỏ H0. DTI > 50: 42,74%, so với 12,20% ở nhóm 30–40.

Kết luận: Có 6/7 giả thuyết bác bỏ được H0. Tuy nhiên, chỉ DTI và LTV đạt mức liên hệ "yếu". Tuổi, loại vay và quy mô vay chỉ "rất yếu". Điểm tín dụng không phân biệt được hai nhóm.

- Ý nghĩa thống kê không đồng nghĩa với liên hệ mạnh. Cần đọc p-value cùng mức hiệu ứng.
- DTI > 50 và LTV > 100% là hai điểm gãy rõ nhất. Kết quả này chỉ áp dụng cho hồ sơ có dữ liệu (133.572 hồ sơ có LTV, 124.549 hồ sơ có DTI), gần như không gồm EQUI.
- `credit_type` có liên hệ mạnh nhất (V = 0,592, mục 3.6) nhưng không đưa vào 7 giả thuyết vì nghi rò rỉ nhãn (EQUI).
- Các kết quả là liên hệ thống kê, không chứng minh nhân quả.

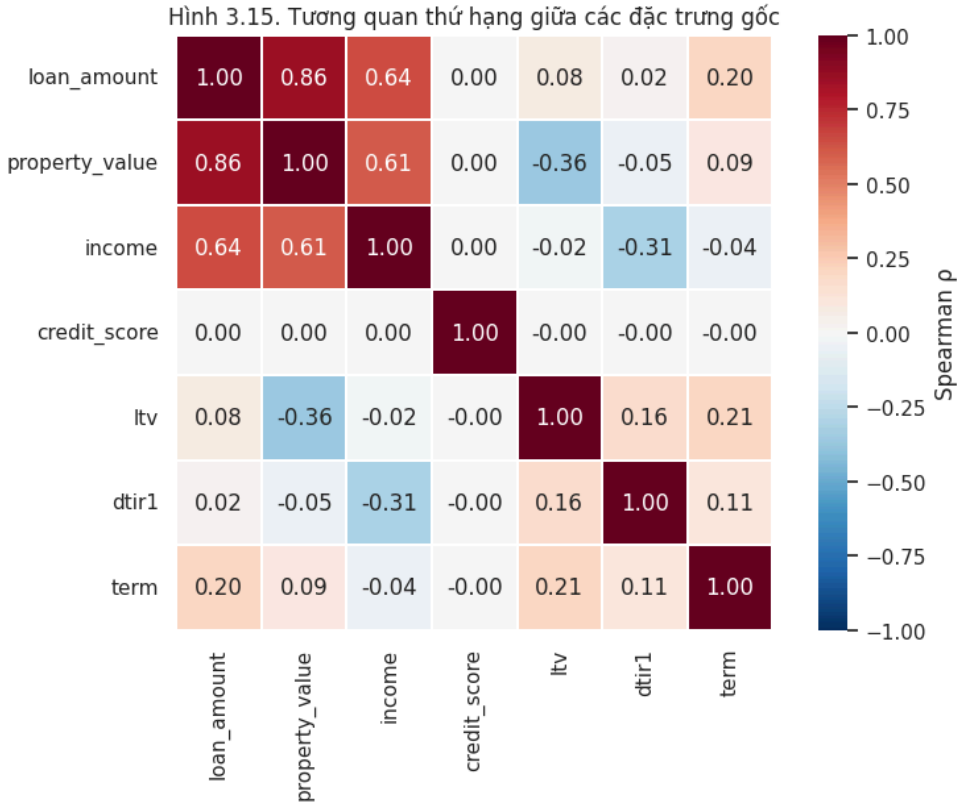
3.6. Phân tích mối quan hệ đa biến

3.6.1. Ma trận tương quan

```
# Hình 3.15 — Tương quan Spearman giữa các biến gốc (không đưa status vào ma trận).
bien_tuong_quan = ['loan_amount', 'property_value', 'income', 'credit_score',
                   'ltv', 'dtir1', 'term']
ma_tran_spearman = eda[bien_tuong_quan].corr(method='spearman')
ma_n = eda[bien_tuong_quan].notna().astype(int).T.dot(
   eda[bien_tuong_quan].notna().astype(int))

fig, ax = plt.subplots(figsize=(8.4, 6.4))
sns.heatmap(ma_tran_spearman, ax=ax, annot=True, fmt='.2f',
            vmin=-1, vmax=1, center=0, cmap='RdBu_r', square=True,
            linewidths=.35, cbar_kws={'label': 'Spearman ρ'})
ax.set_title('Hình 3.15. Tương quan thứ hạng giữa các đặc trưng gốc')
plt.tight_layout(); plt.show()
print('Số cặp quan sát hợp lệ (N) theo từng ô:')
display(ma_n)
```

Hình 3.15. Tương quan thứ hạng giữa các đặc trưng gốc



Số cặp quan sát hợp lệ (N) theo từng ô:

	loan_amount	property_value	income	credit_score	ltv	dtir1	term
loan_amount	148670	133572	139520	148670	133572	124549	148670
property_value	133572	133572	124437	133572	133572	124547	133572
income	139520	124437	139520	139520	124437	124439	139520
credit_score	148670	133572	139520	148670	133572	124549	148670
ltv	133572	133572	124437	133572	133572	124547	133572
dtir1	124549	124547	124439	124549	124547	124549	124549
term	148670	133572	139520	148670	133572	124549	148670

Nhận xét: Heatmap cho thấy khoản vay và giá trị tài sản tương quan thuận mạnh (Spearman ρ ≈ 0,857); thu nhập tương quan thuận với quy mô vay (ρ ≈ 0,642) và với giá trị tài sản (ρ ≈ 0,606). Tương quan giữa ltv và property_value (−0,365) là quan hệ cơ học vì LTV = khoản vay / giá trị tài sản. credit_score không nằm trong cặp nào có |ρ| ≥ 0,30.

Kết luận: Ba biến loan_amount, property_value, income có thông tin chồng lặp, dễ gây đa cộng tuyến khi xây mô hình. Điểm tín dụng độc lập với mọi biến tài chính, củng cố nghi vấn dữ liệu mô phỏng. Tương quan giữa các đặc trưng không phải bằng chứng về tác động gây vỡ nợ.

3.6.2. Phát hiện mối liên hệ mạnh giữa các đặc trưng

```
# Liệt kê duy nhất các cặp đạt |ρ| >= 0,30, kèm N quan sát của từng cặp
cap_manh = pd.DataFrame([
    {'Cặp biến': f'{a} ↔ {b}', 'Spearman ρ': ma_tran_spearman.loc[a, b],
     'N cặp hợp lệ': int(ma_n.loc[a, b])}
    for a, b in combinations(bien_tuong_quan, 2)
    if abs(ma_tran_spearman.loc[a, b]) >= .30
]).sort_values('Spearman ρ', key=lambda s: s.abs(), ascending=False)
print('Bảng 3.6. Các cặp có |ρ| ≥ 0,30:')
display(cap_manh.round(3))
```

Bảng 3.6. Các cặp có |ρ| ≥ 0,30:

	Cặp biến	Spearman ρ	N cặp hợp lệ
0	loan_amount ↔ property_value	0.857	133572
1	loan_amount ↔ income	0.642	139520
2	property_value ↔ income	0.606	124437
3	property_value ↔ ltv	-0.365	133572
4	income ↔ dtir1	-0.307	124439

Nhận xét: Có 5 cặp biến đạt |ρ| ≥ 0,30; mạnh nhất là loan_amount - property_value (0,857). income - dtir1 tương quan nghịch ở mức −0,307, tức thu nhập cao thường đi cùng DTI thấp.

Kết luận: Khi phân tích đồng thời các đặc trưng, cần lưu ý sự trùng lặp thông tin, đồng thời báo cáo N hợp lệ khác nhau theo từng cặp.

3.6.3. Liên hệ biến phân loại với status

```
# Loại 'unknown' ở age và submission_of_application để không nhầm thiếu gốc với nhóm thực.
rows_v = []
for col in all_categorical:
    if col not in eda.columns:
        continue
    tmp = eda[[col, 'status']].dropna()
    if col in ['age', 'submission_of_application']:
        tmp = tmp.loc[tmp[col].ne('unknown')]
    tab = pd.crosstab(tmp[col], tmp['status']).reindex(columns=[0, 1], fill_value=0)
    if min(tab.shape) < 2:
        continue
    chi2 = chi2_contingency(tab, correction=False)[0]
    v = np.sqrt(chi2 / (len(tmp) * min(tab.shape[0]-1, tab.shape[1]-1)))
    rows_v.append({'Biến phân loại': col, 'N hợp lệ': len(tmp), 'Cramér V': v})
bang_v_phan_loai = pd.DataFrame(rows_v).sort_values(
    'Cramér V', ascending=False).reset_index(drop=True)
print('Bảng 3.6b. Liên hệ với status: N tính riêng cho từng biến;'
      ' loại unknown của tuổi và hình thức nộp hồ sơ:')
display(bang_v_phan_loai.round(3))
# Đối chiếu mục 3.5: cùng định nghĩa nhóm tuổi -> cùng kích thước hiệu ứng.
v_tuoi = bang_v_phan_loai.loc[bang_v_phan_loai['Biến phân loại'].eq('age'), 'Cramér V'].iloc[0]
v_h1a = ket_qua_35.loc[ket_qua_35['Mã'].eq('H1a'), 'Hiệu ứng số'].iloc[0]
assert np.isclose(v_tuoi, v_h1a), 'Cramér V tuổi ở 3.5 và 3.6.2 không khớp.'
```

Bảng 3.6b. Liên hệ với status: N tính riêng cho từng biến; loại unknown của tuổi và hình thức nộp hồ sơ:

	Biến phân loại	N hợp lệ	Cramér V
0	credit_type	148670	0.592
1	lump_sum_payment	148670	0.188
2	neg_ammortization	148670	0.156
3	co_applicant_credit_type	148670	0.144
4	submission_of_application	148470	0.121
5	loan_type	148670	0.094
6	gender	148670	0.084
7	loan_limit	148670	0.054
8	region	148670	0.051
9	age	148470	0.050
10	loan_purpose	148670	0.040
11	approv_in_adv	148670	0.037
12	credit_worthiness	148670	0.035
13	occupancy_type	148670	0.030
14	total_units	148670	0.029
15	interest_only	148670	0.014
16	open_credit	148670	0.010
17	credit_score_band	148670	0.008

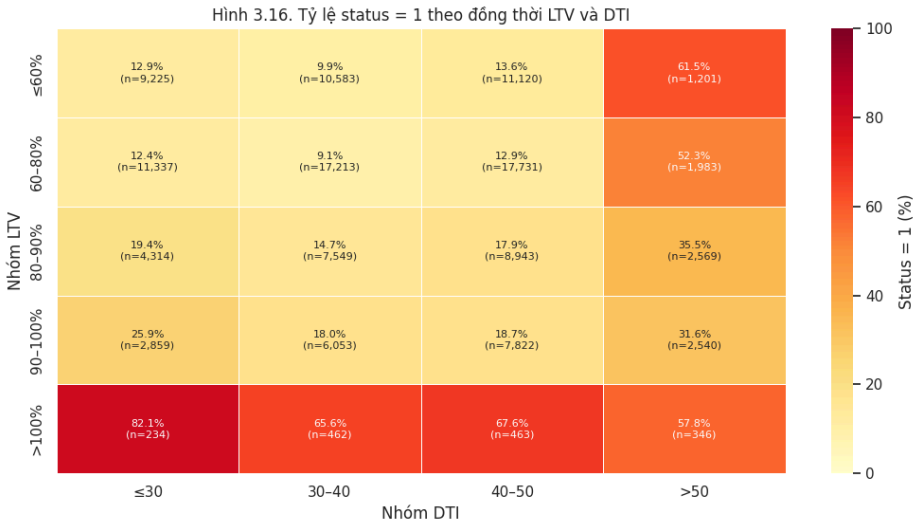
Nhận xét: credit_type có liên hệ mạnh nhất với status trong các biến phân loại (Cramér's V = 0,592), tiếp đến là lump_sum_payment (0,188) và neg_ammortization (0,156). Riêng nhóm tuổi

có V = 0,050 khi loại unknown, thống nhất với mục 3.5. credit_score_band có V thấp nhất (0,008), phù hợp kết quả H3.

Kết luận: Tín hiệu của credit_type quá mạnh so với các biến còn lại, cùng với nhóm EQUI gần như 100% vỡ nợ, cho thấy biến này nhiều khả năng phản ánh quy trình ghi nhận hoặc rò rỉ nhãn, cần xác minh trước khi dùng để dự báo.

3.6.4. Phân tích phân khúc kết hợp

```
# Hình 3.16 — Phân khúc kết hợp LTV × DTI trên cùng một tập hồ sơ đủ hai
chỉ số.
phan_khuc = pd.DataFrame({'LTV': nhom_ltv, 'DTI': nhom_dti,
                          'status': eda['status']}).dropna()
grid_36 = phan_khuc.groupby(['LTV', 'DTI'], observed=True)['status'].agg(
   N='size', So_1='sum', Ty_le='mean')
grid_pct = grid_36['Ty_le'].unstack('DTI').reindex(index=ltv_order,
columns=dti_order) * 100
grid_n = grid_36['N'].unstack('DTI').reindex(index=ltv_order,
columns=dti_order)
# Chỉ hiện ô đủ 100 hồ sơ; ô ít hơn không đủ ổn định để so sánh trực quan.
nhan = grid_pct.copy().astype(object)
for i in range(len(nhan.index)):
   for j in range(len(nhan.columns)):
       n = grid_n.iloc[i, j]
       nhan.iloc[i, j] = f'{grid_pct.iloc[i, j]:.1f}%\n(n={int(n):,})' if
pd.notna(n) and n >= 100 else 'N < 100'
fig, ax = plt.subplots(figsize=(10.5, 5.8))
sns.heatmap(grid_pct.where(grid_n >= 100), annot=nhan, fmt='', ax=ax,
           cmap='YlOrRd', vmin=0, vmax=100, linewidths=.4,
           annot_kws={'fontsize': 8}, cbar_kws={'label': 'Status = 1
(%)'})
ax.set_title('Hình 3.16. Tỷ lệ status = 1 theo đồng thời LTV và DTI')
ax.set_xlabel('Nhóm DTI'); ax.set_ylabel('Nhóm LTV')
plt.tight_layout(); plt.show()
print(f'Mẫu có cả LTV và DTI: {len(phan_khuc):,} hồ sơ; '
     f'tỷ lệ status=1: {100*phan_khuc.status.mean():.2f}%; '
     f'nhóm nhỏ nhất: {int(grid_n.min().min()):,} hồ sơ.')
assert int(grid_n.sum().sum()) == len(phan_khuc)
```



Mẫu có cả LTV và DTI: 124,547 hồ sơ; tỷ lệ status=1: 16.32%; nhóm nhỏ nhất: 234 hồ sơ.

Nhận xét:
Trong 124.547 hồ sơ có cả LTV và DTI, tỷ lệ status = 1 giữa các ô dao động từ 9,1% đến 82,1%; ô nhỏ nhất vẫn có 234 hồ sơ. LTV > 100% có rủi ro cao ở mọi mức DTI (57,8%–82,1%); DTI > 50 có rủi ro cao kể cả khi LTV ≤ 60% (61,5%).
Hai yếu tố không cộng dồn: ô giao nhau (LTV > 100% và DTI > 50) chỉ 57,8%, thấp hơn ô LTV > 100% và DTI ≤ 30 (82,1%).
Vùng thấp nhất là LTV 60–80% kết hợp DTI 30–40 (9,1%)

Kết luận: Mỗi chỉ số nên được dùng như một cảnh báo độc lập thay vì cộng điểm đơn giản. Kết quả có giá trị định hướng phân khúc, nhưng chưa phải mô hình kiểm soát đồng thời các yếu tố gây nhiễu, và mẫu thiếu dữ liệu (gồm EQUI) chưa được đại diện.

3.6.5. Kiểm tra độ nhạy của kết quả

```
# Bảng 3.7 — Sensitivity analysis: luôn đối chiếu hai nhóm trên cùng mẫu.
mau_chung = eda[['ltv', 'dtir1']].notna().all(axis=1)
mau_duong = mau_chung & eda['income'].gt(0)

cac_kich_ban = [
    ('LTV', 'Có LTV', eda['ltv'].notna(), 'ltv', 100),
    ('LTV', 'Có LTV, loại 6 cực trị >1.000%', eda['ltv'].notna() &
eda['ltv'].le(1000), 'ltv', 100),
    ('LTV', 'Có cả LTV và DTI', mau_chung, 'ltv', 100),
    ('LTV', 'Cả hai, income dương', mau_duong, 'ltv', 100),
    ('DTI', 'Có DTI', eda['dtir1'].notna(), 'dtir1', 50),
    ('DTI', 'Có cả LTV và DTI', mau_chung, 'dtir1', 50),
    ('DTI', 'Cả hai, income dương', mau_duong, 'dtir1', 50),
```

```
]
dong_do_nhay = []
for ten, kich_ban, mask, bien, nguong in cac_kich_ban:
    nhom_cao = mask & eda[bien].gt(nguong)
    nhom_thap = mask & eda[bien].le(nguong)
    p_cao = 100*eda.loc[nhom_cao, 'status'].mean()
    p_thap = 100*eda.loc[nhom_thap, 'status'].mean()
    dong_do_nhay.append({'Biến': ten, 'Kịch bản': kich_ban,
                         'N mẫu': int(mask.sum()), 'N nhóm cao':
int(nhom_cao.sum()),
                         'Tỷ lệ nhóm cao (%)': p_cao, 'Tỷ lệ còn lại (%)':
p_thap,
                         'Chênh lệch (đpt)': p_cao-p_thap})
bang_nhay_36 = pd.DataFrame(dong_do_nhay)
display(bang_nhay_36.round(2))
print('Sáu hồ sơ có LTV >1.000%:', int(eda.ltv.gt(1000).sum()),
      '| số hồ sơ trong mẫu có cả LTV và DTI:', int((mau_chung &
eda.ltv.gt(1000)).sum()))

# Đối chiếu hiệu ứng thu nhập khi không xét giá trị 0 và khi chỉ còn mẫu
đủ LTV/DTI.
thu_nhap_nhay = []
for ten, mask in [('Income ghi nhận', eda.income.notna()),
                  ('Income dương', eda.income.gt(0)),
                  ('Income dương + đủ LTV/DTI', mau_duong)]:
    s1 = eda.loc[mask & eda.status.eq(1), 'income']
    s0 = eda.loc[mask & eda.status.eq(0), 'income']
    u, _ = mannwhitneyu(s1, s0, method='asymptotic')
    thu_nhap_nhay.append({'Mẫu': ten, 'N': int(mask.sum()),
                          'Median status=0': s0.median(), 'Median
status=1': s1.median(),
                          'Cliff δ': 2*u/(len(s1)*len(s0)) - 1})
print('Độ nhạy của liên hệ thu nhập với status:')
display(pd.DataFrame(thu_nhap_nhay).round(3))
```

	Biến	Kịch bản	N mẫu	N nhóm cao	Tỷ lệ nhóm cao (%)	Tỷ lệ còn lại (%)	Chênh lệch (đpt)
0	LTV	Có LTV	133572	1799	65.090	15.460	49.630

1	LTV	Có LTV, loại 6 cực trị >1.000%	133566	1793	65.250	15.460	49.790
2	LTV	Có cả LTV và DTI	124547	1505	66.980	15.700	51.270
3	LTV	Cả hai, income dương	124089	1499	66.910	15.480	51.430
4	DTI	Có DTI	124549	8639	42.740	14.350	28.380
5	DTI	Có cả LTV và DTI	124547	8639	42.740	14.350	28.380
6	DTI	Cả hai, income dương	124089	8635	42.730	14.110	28.620

Sáu hồ sơ có LTV >1.000%: 6 | số hồ sơ trong mẫu có cả LTV và DTI: 0
Độ nhạy của liên hệ thu nhập với status:

	Mẫu	N	Median status=0	Median status=1	Cliff δ
0	Income ghi nhận	139520	6,000.000	4,860.000	-0.185
1	Income dương	138260	6,000.000	5,040.000	-0.155
2	Income dương + đủ LTV/DTI	124089	6,000.000	4,680.000	-0.213

Nhận xét: Chênh lệch tỷ lệ status = 1 giữa LTV > 100% và phần còn lại giữ ở khoảng 49,63–51,43 điểm phần trăm qua các kịch bản; với DTI > 50 là 28,38–28,62 điểm. Cliff's δ của thu nhập thay đổi từ - 0,155 đến - 0,213 tùy mẫu (mạnh hơn khi có income = 0: −0,185).

Kết luận: Tín hiệu LTV/DTI ổn định trong các phép lọc đã thử, còn mức độ liên hệ thu nhập nhạy với cách chọn mẫu, nên cần báo cáo kèm mẫu sử dụng.

3.7. Tổng hợp Deep Insights

1. Chất lượng dữ liệu quyết định cách đọc mọi kết quả

Tỷ lệ status = 1 là 24,64% trên toàn bộ nhưng chỉ còn 16,13% trong mẫu có LTV. Nguyên nhân là nhóm EQUI (15.297/15.298 hồ sơ vỡ nợ, thiếu LTV gần như toàn bộ), cộng với interest_rate_spread thiếu đúng bằng status = 1.

Hàm ý: kết quả chỉ đúng với hồ sơ có dữ liệu; các biến lãi suất, phí và credit_type không nên dùng dự báo nếu chưa xác minh thời điểm ghi nhận

2. DTI > 50 và LTV > 100% là hai ngưỡng rủi ro rõ nhất

Tỷ lệ vỡ nợ là 42,74% (DTI > 50) so với 12,20% (DTI 30–40), và 65,09% (LTV > 100%) so với 12,94% (LTV 60–80%). Chênh lệch ổn định qua các kịch bản kiểm tra độ nhạy (28,4–28,6 và 49,6–51,4 đpt). Hai nhóm chỉ chiếm 6,9% và 1,35% mẫu nhưng chứa 18,2% và 5,4% số hồ sơ vỡ nợ.

Hàm ý: nên rà soát có trọng tâm các nhóm này, không dùng để tự động từ chối

3. Hai chỉ số không cộng dồn

LTV > 100% rủi ro cao ở mọi mức DTI (57,8–82,1%), còn DTI > 50 cao kể cả khi LTV ≤ 60% (61,5%). Ô giao nhau (LTV > 100% và DTI > 50) chỉ 57,8%, thấp hơn ô LTV > 100% và DTI ≤ 30 (82,1%); vùng thấp nhất là 9,1%.

Hàm ý: nên dùng mỗi chỉ số như một cảnh báo độc lập, không cộng điểm đơn giản.

4. Thu nhập thấp, khoản vay nhỏ và type2 có liên hệ nhưng yếu hoặc không đơn điệu

Tỷ lệ vỡ nợ giảm từ 32,98% (thu nhập Q1) xuống 20,22% (Q4); khoản vay Q1 là 30,50% so với 21,36% ở Q4 và 22,49% ở Q5; type2 là 34,54% so với 22,77% ở type1 (V = 0,094). Nhóm income = 0 (99,37% vỡ nợ) rất bất thường nên cần xem riêng. Vì loan_amount và income tương quan cao (ρ = 0,642), hai hiệu ứng này khó tách rời

5. Điểm tín dụng không phân biệt được hai nhóm trong bộ dữ liệu này

Tỷ lệ vỡ nợ theo bốn khoảng điểm chỉ dao động 24,29–25,17%, p = 0,1243, δ ≈ 0,005. Phân phối điểm gần phẳng trong 500–900 và không tương quan mạnh với biến tài chính nào, nên có thể đây là dữ liệu mô phỏng hoặc ẩn danh

Hàm ý: không kết luận điểm tín dụng vô dụng ngoài thực tế, chỉ kết luận bộ dữ liệu này chưa cho thấy tín hiệu.

Kết luận: Chương 3 xác định được các phân khúc rủi ro cao (DTI > 50, LTV > 100%) và các giới hạn lớn của dữ liệu (thiếu theo status, EQUI, nghi rò rỉ). Chương 4 sẽ tập trung vào ba khuyến nghị: kiểm soát chất lượng và thời điểm ghi nhận dữ liệu; rà soát có trọng tâm LTV > 100%, DTI > 50, income = 0; nêu rõ đây là mối liên hệ thống kê, chưa phải nhân quả hay mô hình dự báo